


WORKSHOP · 1

Inferencia causal y evaluación de impacto

De la correlación a la causa: qué se puede afirmar con datos, y cuándo.



FIC — Economic Research

Contenido basado en Causal Inference: The Mixtape (Scott Cunningham) y en el curso de Evaluación de Impacto del Banco Mundial (edX).

La ruta del workshop

Seis bloques encadenados: cada uno explica por qué hace falta el siguiente.



Lo que se lleva: un criterio para leer, encargar y defender evidencia — no un recetario de fórmulas. La pregunta de fondo será siempre la misma: ¿contra qué se está comparando?



Correlación no es causalidad

El obstáculo no es estadístico ni computacional: es de diseño. Más datos no lo resuelven.

TRES CORRELACIONES CONOCIDAS



«Un año más de educación se asocia a 9 % más de salario.»

¿Es el retorno de la educación, o la habilidad que no se observa?



«Las ciudades con más policía registran más delito.»

¿La policía genera delito, o se despliega donde ya lo hay?



«Los municipios del programa crecieron más.»

¿Fue el programa, o se focalizó donde ya estaba despegando?



La pregunta correcta

¿Qué habría pasado con estas mismas unidades si no hubieran recibido el tratamiento?

Ese escenario no existe en los datos. Toda la disciplina consiste en construir un sustituto creíble para él.



El contrafactual: lo que nunca se observa

El problema fundamental de la inferencia causal: de cada unidad vemos un solo mundo, no los dos.

LO QUE SÍ SE VE

El resultado de la unidad tratada, después de tratarla.

El ingreso del hogar que recibió la transferencia. El empleo del municipio donde entró el programa. Está en la base de datos.

LO QUE HARÍA FALTA

Esa misma unidad, en ese mismo momento, sin el tratamiento.

Nunca se observa. No es un problema de muestreo ni de presupuesto: es lógicamente imposible.

$$\tau_i = Y_i(1) - Y_i(0)$$

efecto sobre la unidad i — nunca estimable

$$ATE = E[Y_i(1)] - E[Y_i(0)]$$

efecto promedio en la población — sí estimable, con el diseño adecuado

Como el segundo término falta, todo método de evaluación es una estrategia para reemplazarlo: un grupo de comparación que represente lo que le habría ocurrido al grupo tratado. La discusión metodológica nunca es sobre el estimador — es sobre si ese reemplazo es creíble.



De dónde viene el sesgo

Comparar tratados con no tratados mezcla, en una sola cifra, dos cosas de naturaleza distinta.

Diferencia observada entre tratados y no tratados

Efecto causal del tratamiento

lo único que se quiere medir

Sesgo de selección

de tamaño y signo desconocidos

Qué es el sesgo

La diferencia que ya existía entre los dos grupos antes del tratamiento. Los tratados suelen ser distintos justamente por las razones que los llevaron a tratarse.

Por qué no se ve

Si esas diferencias estuvieran medidas, se controlarían. El problema son las que no están en la base: habilidad, capacidad institucional, expectativas, información privada.

Por qué duele

Ni más observaciones ni un modelo más sofisticado separan los dos bloques. Solo lo hace el diseño: la forma en que se decidió quién recibe el tratamiento.

En una frase — el trabajo del investigador no es estimar la diferencia observada (eso lo hace cualquiera), sino argumentar por qué el segundo bloque es despreciable.



El estimador MCO y por qué no es causal

Mínimos cuadrados ordinarios estima muy bien una asociación. La causalidad no viene del estimador: viene del supuesto.

$$Y_i = \beta_0 + \beta_1 T_i + \beta_2 X_i + u_i$$

Y: resultado de interés · T: tratamiento · X: controles observados · u: todo lo demás

Qué estima β_1

El cambio promedio en Y asociado a un cambio en T, una vez descontado lo que X explica. Es una descripción de los datos, y como tal es correcta.

Qué hace falta para leerlo como efecto

Que u —todo lo no observado— no se relacione con T. Es decir: que la asignación del tratamiento no dependa de nada que también afecte a Y.

Qué ocurre si no se cumple

β_1 absorbe también el efecto de lo omitido. Deja de tener magnitud interpretable y, con frecuencia, hasta el signo cambia.

Ese supuesto no se contrasta con los datos: se defiende con el diseño. Agregar más controles no arregla lo que no está medido — solo desplaza el problema.



Las cuatro caras de la endogeneidad

Cuatro formas distintas de romper el mismo supuesto. Conviene saber cuál se está enfrentando, porque el remedio cambia.



Variable omitida

La habilidad no observada en la ecuación de Mincer: eleva a la vez los años de estudio y el salario, así que el retorno estimado la absorbe.



Causalidad inversa

El pie de fuerza policial responde al crimen tanto como el crimen responde al pie de fuerza. La flecha apunta en los dos sentidos a la vez.



Autoselección

Quien se inscribe en un programa de capacitación laboral no es comparable con quien no lo hace: es el problema que LaLonde (1986) volvió famoso.



Error de medición

El ingreso autorreportado en encuestas de hogares está mal medido, y eso atenúa el coeficiente hacia cero: el efecto real se subestima.

Las tres primeras sesgan en dirección desconocida. La cuarta sesga hacia cero — es la única que da un error «conservador».



Variables instrumentales (2SLS)

La idea: quedarse solo con la parte de la variación en el tratamiento que proviene de algo ajeno al problema.

PRIMERA ETAPA

$$T_i = \pi_0 + \pi_1 Z_i + \pi_2 X_i + v_i$$

Se explica el tratamiento con el instrumento Z y se guarda el valor predicho.

SEGUNDA ETAPA

$$Y_i = \beta_0 + \beta_1 \hat{T}_i + \beta_2 X_i + \varepsilon_i$$

Se usa ese valor predicho, ya limpio de lo que contaminaba a T, en lugar de T.

LO QUE EL INSTRUMENTO DEBE CUMPLIR

1 • Relevancia

Z mueve de verdad a T. Se contrasta con los datos. Un instrumento débil sesga más que no usar ninguno.

2 • Restricción de exclusión

Z afecta a Y únicamente a través de T. No se contrasta: se argumenta con conocimiento del contexto.

3 • Independencia

Z es, para efectos prácticos, tan bueno como aleatorio. Nada que afecte a Y explica también a Z.

Caso canónico — Angrist y Krueger (1991, QJE) instrumentan los años de educación con el trimestre de nacimiento: la fecha de corte escolar y la edad mínima para desertar generan variación ajena a la habilidad.



El experimento aleatorio

Si el tratamiento se asigna por razones que también afectan al resultado, la salida es sacar esa decisión de manos de todos y sortearla.





Por qué la aleatorización identifica el efecto

Un solo argumento, y es el más poderoso de toda la caja de herramientas.

Si el sorteo decide quién entra, los dos grupos son iguales en promedio antes del tratamiento — en todo, no solo en lo que se midió. Cualquier diferencia posterior solo puede venir del tratamiento.

Balance en lo observable

Se verifica y se reporta. En Hyderabad, la tabla compara los 52 barrios tratados con los 52 de control en población, ingreso y actividad empresarial previa.

Balance en lo no observable

No se verifica: se deduce del sorteo. Esto es exactamente lo que ningún método no experimental puede comprar, por sofisticado que sea.

El control como contrafactual

El grupo de control deja de ser «los otros» y pasa a ser una estimación creíble de lo que le habría pasado al grupo tratado.

Matiz importante: aleatorizar garantiza balance en expectativa, no en una muestra concreta. Con pocas unidades puede salir un desbalance por puro azar — por eso la tabla de balance se reporta siempre, y por eso el tamaño de muestra se calcula antes.



Los supuestos que el sorteo no regala

Aleatorizar resuelve la selección. Estas cuatro condiciones siguen siendo responsabilidad del diseño.



Asignación aleatoria y respetada

La regla se define, se documenta y no se toca. Reasignar «casos especiales» sobre la marcha destruye el experimento sin dejar rastro.



No interferencia entre unidades (SUTVA)

En Hyderabad otras microfinancieras podían entrar en los barrios de control: el contrafactual no era «sin crédito», sino «sin Spandana».



Cumplimiento

Quien fue asignado al tratamiento lo recibe, y quien fue asignado al control no. Rara vez se cumple del todo — es el bloque siguiente.



Poder estadístico


Muestra suficiente para detectar el efecto que importaría. Sin poder, un «no hay efecto» no significa nada. Es el bloque 5.

Y una advertencia final: validez externa. Un efecto bien estimado vale para esa población y ese contexto — que funcione en Hyderabad no garantiza que funcione en Cali.



La econometría (1): la diferencia de medias

El estimador del efecto causal es una resta: el promedio del grupo tratado menos el promedio del grupo de control.



Las dos curvas se solapan casi por completo: el efecto no está en «quién gasta mucho», sino en el desplazamiento del centro. Cifras ilustrativas con la estructura del experimento de Hyderabad.

$$\hat{\tau} = \bar{Y}_T - \bar{Y}_C$$

Media del grupo de control

100,4

Media del grupo de tratamiento

112,1

DIFERENCIA ESTIMADA

+11,7

error estándar 4,3 · valor p 0,006

Qué agrega la prueba t

Nada sobre causalidad: solo si la resta se distingue del ruido.




La econometría (2): la regresión

La misma resta, escrita como modelo. La regresión no agrega causalidad: agrega errores estándar, controles y disciplina.

$$Y_i = \alpha + \beta T_i + \gamma X_i + \varepsilon_i$$

La regresión parte el promedio tratado en dos



β es la diferencia de medias

Con T binario, devuelve exactamente la resta de la lámina anterior.

Los controles X dan precisión

No corrigen sesgo: en un experimento válido no queda sesgo.

Agrupar los errores estándar

Se sorteó el barrio, así que los errores se agrupan por barrio.

Especificar antes de mirar

Variables y subgrupos se fijan antes de ver los resultados.



Cumplimiento imperfecto: ITT y LATE

Se asigna, pero no todos obedecen. Hay quien fue invitado y no fue, y quien no fue invitado y se las arregló para entrar.

CUATRO TIPOS DE UNIDAD

Cumplidores

Toman el crédito porque abrió la sucursal. Son el único grupo sobre el que el experimento informa directamente.

Siempre-tomadores

Se habrían endeudado con otra microfinanciera de todos modos. La asignación no los mueve.

Nunca-tomadores

No toman crédito aunque tengan la sucursal enfrente. Tampoco los mueve la asignación.

Desafiantes

Harían justo lo contrario de lo asignado. Se supone que no existen (monotonidad).

ITT · Intención de tratar

Compara los 52 barrios tratados contra los 52 de control, sin mirar quién tomó el crédito. Siempre estimable y nunca sesgado. Responde la pregunta de política: ¿qué logra abrir la sucursal, con el nivel real de adherencia que tenga?

LATE · Efecto sobre los cumplidores

$$LATE = \frac{ITT}{\text{tasa de cumplimiento}}$$

En Hyderabad la apertura subió la toma de crédito 8,4 puntos porcentuales. Es un 2SLS con la asignación como instrumento, y vale solo para ese subgrupo.

El error más común: comparar solo a quienes efectivamente tomaron el tratamiento contra el resto. Eso reintroduce la selección por la puerta de atrás y deshace todo lo que el sorteo había ganado.



Atrición: cuando la gente desaparece

Si quienes abandonan el estudio son distintos en cada grupo, la muestra final ya no está balanceada — y el sorteo deja de protegernos.

Por qué importa

Si el programa hace que los peores casos del grupo tratado se retiren, el promedio que queda mejora sin que nada haya mejorado. El efecto medido es un artefacto.

Lo primero, siempre: reportarla

Tasa de atrición por grupo y comparación de características de quienes salen. Si las tasas son parecidas y los perfiles también, el riesgo es bajo.

CUANDO LA ATRICIÓN ES SERIA: ACOTAR

Cotas de Manski

Sin supuesto alguno: a cada dato faltante se le imputa el peor valor posible, y luego el mejor. El efecto real está entre esos dos extremos. Es honesto por construcción, pero el rango suele salir tan ancho que no permite concluir.

Cotas de Lee

Añade un supuesto de monotonicidad: la atrición empuja en una sola dirección. Con él se recorta el grupo que perdió menos gente hasta igualar las tasas. El intervalo se estrecha bastante, al precio de ese supuesto.


Las cotas no entregan un número: entregan un intervalo honesto. Si la conclusión sobrevive a todo el rango, es robusta; si se cae en la mitad del rango, el dato no alcanza para sostenerla.




Clusterización y estratificación

Dos decisiones que se toman al diseñar el sorteo. Una cuesta poder; la otra lo gana.

Se sortea el conglomerado entero, no la persona



Escuela 1 · tratamiento



Escuela 2 · tratamiento



Escuela 3 · control



Escuela 4 · control

Los alumnos de una misma escuela se parecen entre sí: cada uno aporta menos información nueva que si hubieran sido sorteados de forma independiente. Eso es lo que penaliza el efecto de diseño.

EFFECTO DE DISEÑO

$$DEFF = 1 + (m - 1)\rho$$

m: tamaño del conglomerado · ρ : correlación intraclase (qué tanto se parecen entre sí)

Regla práctica: clusterizar solo cuando la naturaleza del tratamiento lo obliga; estratificar casi siempre que se pueda.

CLUSTERIZACIÓN

Cuándo se usa

Cuando el tratamiento no se puede dar a una persona sin dárselo a todo su grupo (una escuela, un barrio, un municipio), o cuando habría contagio entre vecinos. Se sortea el conglomerado completo.

Qué cuesta

Los errores estándar se agrupan al nivel del sorteo y el poder cae: lo que manda ya no es el número de personas, sino el número de conglomerados.

ESTRATIFICACIÓN


Sortear por bloques

Se agrupan las unidades por características previas —región, tamaño, resultado de línea base— y se aleatoriza dentro de cada bloque. Garantiza balance en esas variables en lugar de dejarlo al azar, reduce la varianza y mejora el poder sin costar muestra. Los estratos entran después como controles en la regresión.



Tipos de error y el poder

Toda prueba puede fallar de dos maneras opuestas. La significancia controla una; el poder controla la otra.



ERROR TIPO I · α

Concluir que hay efecto cuando no lo hay. Es el nivel de significancia: se fija de antemano, casi siempre en 0,05.

ERROR TIPO II · κ

No detectar un efecto que sí existe. No se fija: resulta del diseño —muestra, varianza y tamaño del efecto real—.

$$\text{PODER} = 1 - \kappa$$

0,80

Convención habitual: detectar el efecto en 8 de cada 10 experimentos como este.

Bajar α —ser más exigente para declarar un hallazgo— sube κ si nada más cambia. Solo el diseño, con más muestra o menos varianza, mejora las dos cosas a la vez.



La fórmula de poder: el MDE

El cálculo de poder no se hace al final: define el tamaño de muestra antes de salir a campo.

$$MDE = (t_{1-\kappa} + t_{\alpha/2}) \sqrt{\frac{1}{P(1-P)}} \sqrt{\frac{\sigma^2}{N}}$$

El efecto más pequeño que el diseño alcanza a detectar. Si el efecto real es menor que el MDE, el experimento dirá «sin efecto» aunque lo haya.

α

Significancia

Probabilidad de error tipo I. Se fija: casi siempre 0,05.

$1 - \kappa$

Poder

Probabilidad de detectar el efecto si existe. Se fija: casi siempre 0,80.

P

Reparto de la muestra

Proporción asignada a tratamiento. Con costos iguales, el óptimo es 0,5.

σ^2

Varianza del resultado

Cuánto ruido tiene la variable. Se estima de una línea base.

N

Tamaño de muestra

Número de unidades. Es la palanca que el investigador controla.

QUÉ MUEVE EL MDE

N ↑ → MDE ↓

pero a razón de $\sqrt{N}$: cuadruplicar la muestra solo lo reduce a la mitad

σ^2 ↓ → MDE ↓

línea base, controles y estratificación bajan la varianza

P → 0,5 → MDE ↓

el reparto equilibrado entre brazos es el más eficiente

poder ↑ o α ↓ → MDE ↑

ser más exigente cuesta muestra, o cuesta detección

EL ORDEN


$$N_{\text{efectiva}} = \frac{N \times (1 - a)}{DEFF}$$

Con conglomerados o atrición esperada (a), primero se calcula la muestra efectiva; el MDE se computa sobre esa N, no sobre la inicial.



Panel: efectos fijos

Seguir a las mismas unidades en el tiempo y quedarse solo con la variación interna de cada una.



Los efectos fijos descartan la comparación entre unidades y usan solo la variación interna de cada una.

Comparar entre municipios puede dar hasta el signo contrario que comparar cada municipio consigo mismo. α_i absorbe todo lo que distingue de forma permanente a una unidad; λ_t , lo que afecta a todas en un mismo periodo.

$$Y_{it} = \alpha_i + \lambda_t + \beta T_{it} + \varepsilon_{it}$$

EL SUPUESTO CLAVE

Todo lo omitido que importa es fijo en el tiempo. Si hay algo no observado que cambia junto con el tratamiento —una reforma local, un cambio de gobierno—, los efectos fijos no lo tocan.

CÓMO SE DEFIENDE


Mostrar que el resultado no depende de incluir o no tendencias específicas por unidad, y discutir qué podría estar cambiando a la vez que el tratamiento.

Acemoglu, Naidu, Restrepo y Robinson (2019, JPE): «Democracy Does Cause Growth».



DiD: diferencias en diferencias

Comparar el cambio antes-después del grupo tratado contra el cambio del grupo no tratado.



Antes del tratamiento las dos series se mueven en paralelo: eso es lo que hay que mostrar.

La primera resta elimina todo lo que es fijo en cada grupo; la segunda, todo lo que afecta por igual a ambos en el tiempo. Lo que queda es el efecto — siempre que el contrafactual punteado sea creíble.

$$\hat{\tau}_{DiD} = (\bar{Y}_T^{post} - \bar{Y}_T^{pre}) - (\bar{Y}_C^{post} - \bar{Y}_C^{pre})$$

EL SUPUESTO CLAVE

Tendencias paralelas: sin el tratamiento, los dos grupos habrían evolucionado igual. No es que sean iguales en nivel, es que se mueven al mismo ritmo.

CÓMO SE DEFIENDE


Graficar varios periodos previos y mostrar que las series ya venían paralelas; correr un estudio de eventos y verificar que los coeficientes pre-tratamiento son cero.

Card y Krueger (1994, AER): salario mínimo y empleo en Nueva Jersey frente a Pensilvania.



RDD: regresión discontinua

Comparar a quienes quedaron justo por encima con quienes quedaron justo por debajo de un umbral.



Solo importa lo que pasa muy cerca del corte: ahí los dos grupos son casi idénticos.

Justo alrededor del corte, quedar dentro o fuera del programa es casi un sorteo: nadie controla su puntaje con esa precisión. Por eso el RDD es el diseño no experimental más creíble, y por eso solo informa cerca del umbral.

$$\hat{\tau}_{RDD} = \lim_{x \downarrow c} E[Y|x] - \lim_{x \uparrow c} E[Y|x]$$

EL SUPUESTO CLAVE

Nada más cambia en el umbral, y las unidades no pueden manipular su posición respecto al corte para entrar al programa.

CÓMO SE DEFIENDE


Contraste de McCrary sobre la densidad alrededor del corte, verificar que las covariables previas no saltan, y mostrar que el resultado aguanta cambiar el ancho de banda.

Angrist y Lavy (1999, QJE): la regla de Maimónides y el tamaño de la clase.



PSM: emparejamiento por propensión

Comparar tratados y no tratados que tenían la misma probabilidad estimada de haber sido tratados.



Solo se comparan unidades dentro del soporte común; el resto se descarta y la muestra cambia.

Se estima la probabilidad de tratarse a partir de las covariables y se emparejan unidades con puntajes parecidos. Fuera del soporte común no hay con quién comparar: esas unidades se descartan y la población sobre la que se concluye cambia.

$$e(X_i) = \Pr(T_i = 1 \mid X_i)$$

EL SUPUESTO CLAVE

Selección sobre observables: una vez controlado X , quién recibió el tratamiento es como si fuera aleatorio. Es el supuesto más exigente de todos y no se puede contrastar.

CÓMO SE DEFIENDE

Mostrar balance de covariables después del emparejamiento, reportar el soporte común y hacer análisis de sensibilidad a un confusor no observado (cotas de Rosenbaum).

Dehejia y Wahba (2002, REStat): reevaluación de los programas de capacitación de LaLonde.



Cómo elegir el diseño

La pregunta guía no es «qué método sé usar», sino «de dónde viene la variación en el tratamiento».

¿Se puede decidir por sorteo quién recibe el tratamiento?



RCT

Banerjee et al. (2015), AEJ: Applied.

¿La elegibilidad depende de un umbral (puntaje, edad, tamaño)?



RDD

Angrist y Lavy (1999), QJE.

¿Hay datos antes y después, y un grupo no afectado?



DiD

Card y Krueger (1994), AER.

¿Se observa a las mismas unidades varias veces?



Panel · EF

Acemoglu et al. (2019), JPE.

¿Existe una fuente de variación ajena (sorteo, regla, geografía)?



IV · 2SLS

Angrist y Krueger (1991), QJE.

Solo un corte transversal y buenos observables



PSM

Dehejia y Wahba (2002), REStat.

El orden no es de dificultad técnica sino de credibilidad: cuanto más arriba, menos hay que pedirle al lector que acepte sin evidencia.

EN SÍNTESIS

Estimar bien no es el problema. El problema es comparar bien.

El diseño manda sobre el modelo

La credibilidad viene de cómo se asignó el tratamiento, no de la sofisticación de la estimación.

Todo estimador vive de un supuesto

El trabajo consiste en hacerlo explícito, defenderlo y mostrar qué pasa si falla.

Sin contrafactual no hay efecto

Un número sin grupo de comparación creíble es una correlación bien vestida.

Decidir antes de mirar

Qué se mide, contra quién se compara y qué efecto mínimo importaría: las tres, antes de ver los datos.



Para seguir por cuenta propia

Todo lo de esta sesión está desarrollado, con ejemplos y código, en estas cuatro fuentes.



Causal Inference: The Mixtape *Scott Cunningham (Yale University Press, 2021).*

El texto base de esta sesión. Explica cada diseño con intuición antes que con álgebra, y trae código replicable en R y Stata. Versión en línea de acceso libre.



Impact Evaluation Methods for Policy Makers *Banco Mundial · edX.*

Curso gratuito, orientado a quien encarga y usa evaluaciones más que a quien las estima. Fuente de la estructura de este workshop.



La evaluación de impacto en la práctica *Gertler, Martínez, Premand, Rawlings y Vermeersch (Banco Mundial, 2ª ed.).*

Manual operativo en español, de descarga libre. Su capítulo de poder desarrolla el efecto de diseño y el MDE paso a paso.



Mastering 'Metrics *Angrist y Pischke (Princeton, 2015).*

El complemento breve: las cinco herramientas centrales contadas con ejemplos memorables y casi sin notación.

Diseño y paleta índigo tomados de la guía Análisis Real para Economía; estructura de láminas adaptada de la plantilla del Semillero de Economía del Crimen.